Projet de régression linéaire

Prédiction du BMI à partir de la pression artérielle

Réalisé par :	LOUATI Malek
	EL HDOUR Hafssa
	DIENG Abdou
Module :	Régression linéaire
Année universitaire :	2025–2026
Encadré par :	Christine Malot
Date :	12/06/2026

Rapport réalisé dans le cadre du projet de régression linéaire

Table des matières

Avant-propos **2**

1 Introduction **3**

2 Présentation du dataset **3**

3 Nettoyage des données **4**

4 Analyse descriptive **4**
4.1 Distribution des variables 4
4.2 Corrélations 6

5 Étude de la linéarité **6**

6 Régression linéaire simple **8**
6.1 Test d'hypothèse sur la pente 9

7 Régression linéaire multiple **10**

8 Sélection de variables **11**
8.1 Méthode stepwise 11

9 Comparaison des modèles **12**

10 Cp de Mallows **12**

11 Sélection par Lasso **13**

12 Analyse de la variance **15**

13 Diagnostic du modèle final **16**

14 Analyse des résidus **17**
14.1 Test de normalité des résidus 18
14.2 Test d'homoscédasticité 19
14.3 Test d'indépendance 19

15 Points influents **19**

16 Prédiction **20**

17 Interprétation et validité du modèle final **21**

18 Conclusion **21**

Annexe – Code R complet **23**

Avant-propos

Dans ce projet, nous avons choisi de travailler sur un dataset réel portant sur le BMI et la pression artérielle. L'idée de présenter l'analyse sous une forme plus explicable a été inspirée par un exemple donné par la professeure. Nous avons donc décidé de garder une démarche académique en statistique, tout en donnant au rapport une interprétation plus concrète.

Le but n'est pas de réaliser un vrai diagnostic médical. Le modèle construit dans ce rapport sert uniquement à appliquer les méthodes de régression linéaire vues en cours. À la fin de l'analyse, le BMI prédit est transformé en catégorie fictive afin de rendre le résultat plus facile à interpréter.

L'objectif principal est donc de construire un modèle de régression linéaire permettant de prédire le BMI à partir de la pression systolique et de la pression diastolique.

1 Introduction

La régression linéaire est une méthode statistique permettant d'étudier la relation entre une variable réponse quantitative et une ou plusieurs variables explicatives. Dans ce projet, la variable réponse étudiée est le BMI, aussi appelé indice de masse corporelle.

Les variables explicatives utilisées sont la pression systolique et la pression diastolique. L'objectif est d'étudier si ces deux variables permettent d'expliquer, même partiellement, les variations du BMI.

Ce rapport présente les étapes suivantes : préparation du dataset, analyse descriptive, modélisation par régression linéaire simple, régression linéaire multiple, sélection de variables, comparaison des modèles, diagnostic du modèle final et prédiction.

2 Présentation du dataset

Le dataset utilisé dans ce projet est un jeu de données réel contenant des informations relatives au BMI et à la pression artérielle.

Les variables principales sont :

— **BMI** : indice de masse corporelle ;
— **BP_Sy** : pression artérielle systolique ;
— **BP_Di** : pression artérielle diastolique.

Après renommage dans R, les variables utilisées dans l'analyse sont :

— `bmi` ;
— `pression_systolique` ;
— `pression_diastolique`.

```
'data.frame':   7132 obs. of  3 variables:
 $ BMI   : num  31.7 21.5 18.1 23.7 38.9 21.3 19.7 23.5 39.9 22.5
    ...
 $ BP_Sy: int  164 126 136 146 120 112 117 97 128 126 ...
 $ BP_Di: int  66 74 71 82 83 63 56 66 75 78 ...
```

Variable	Type	Rôle dans l'analyse
`BMI`	Numérique	Variable réponse
`BP_Sy`	Entier	Variable explicative
`BP_Di`	Entier	Variable explicative

TABLE 1 – Structure des variables du dataset

Information	Valeur
Nombre d'observations	7132
Nombre de variables	3

TABLE 2 – Dimensions du dataset avant nettoyage

3 Nettoyage des données

Avant de construire les modèles, un nettoyage des données a été effectué. Les valeurs manquantes ont été recherchées, puis les lignes incomplètes ont été supprimées. Les doublons ont également été identifiés et retirés lorsque nécessaire.

Les variables ont ensuite été converties au format numérique afin de pouvoir être utilisées dans les modèles de régression linéaire.

Variable	Nombre de valeurs manquantes
`bmi`	114
`pression_systolique`	989
`pression_diastolique`	989
Total	2092

TABLE 3 – Valeurs manquantes dans le dataset

4 Analyse descriptive

L'analyse descriptive permet de mieux comprendre la structure du dataset avant de construire les modèles. Elle consiste à observer les principales statistiques des variables : minimum, maximum, moyenne, médiane et écart-type.

Variable	Min	1er Qu.	Médiane	Moyenne	3e Qu.	Max
BMI	13.1	22.7	27.2	28.10	32.3	74.8
Pression systolique	52.0	106.0	117.0	120.5	131.0	219.0
Pression diastolique	31.0	64.0	71.0	72.14	80.0	141.0

TABLE 4 – Statistiques descriptives après nettoyage

4.1 Distribution des variables

Les histogrammes permettent d'observer la distribution du BMI, de la pression systolique et de la pression diastolique.

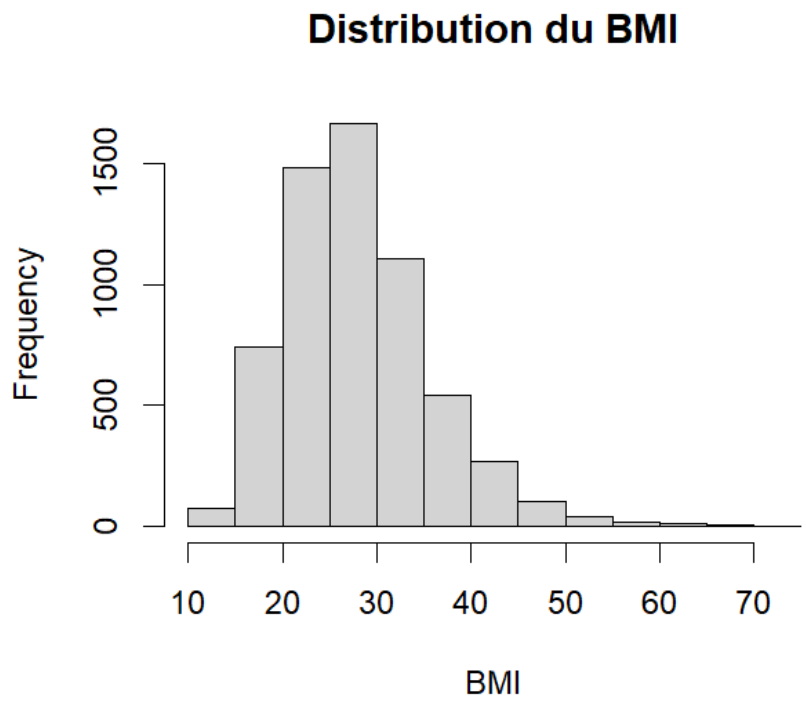


FIGURE 1 – Distribution du BMI

La distribution du BMI est légèrement asymétrique à droite. La majorité des individus possède un BMI compris entre 20 et 35, avec quelques valeurs élevées observées.

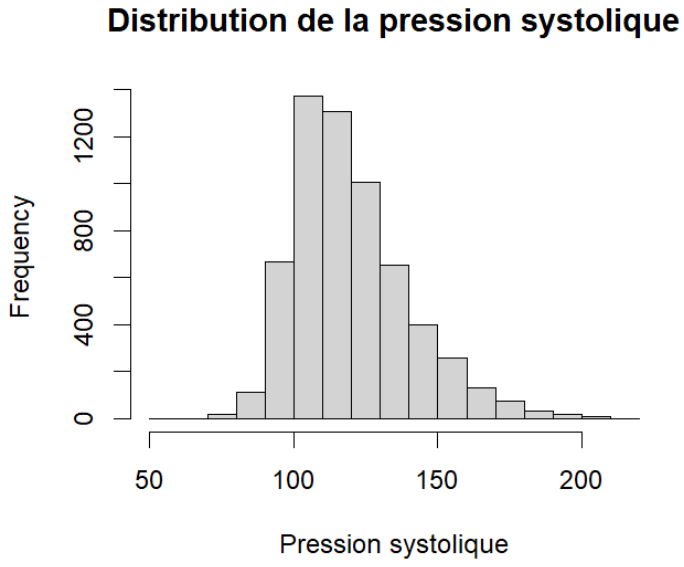


FIGURE 2 – Distribution de la pression systolique

La pression systolique est centrée autour de 120 mmHg et présente une distribution proche d'une forme en cloche, avec quelques valeurs élevées.

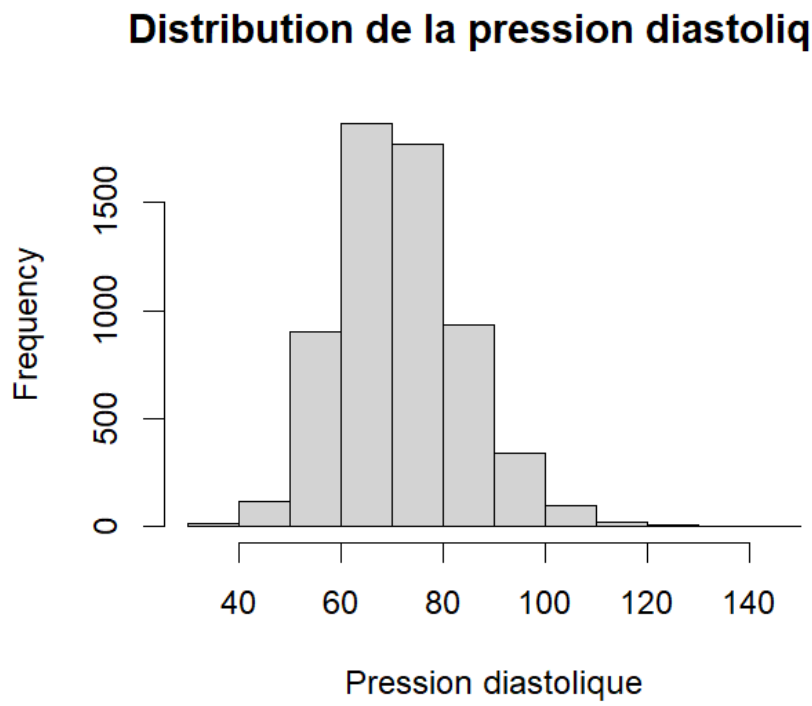


FIGURE 3 – Distribution de la pression diastolique

La pression diastolique est principalement concentrée entre 60 et 80 mmHg et suit une distribution relativement symétrique.

4.2 Corrélations

Les corrélations permettent d'avoir une première idée de la relation linéaire entre le BMI et les variables de pression artérielle.

	BMI	Pression systolique	Pression diastolique
BMI	1.000	0.195	0.333
Pression systolique	0.195	1.000	0.671
Pression diastolique	0.333	0.671	1.000

TABLE 5 – Matrice de corrélation entre les variables quantitatives

Matrice de corrélation : Le BMI est positivement corrélé aux deux mesures de pression artérielle. La corrélation est plus forte avec la pression diastolique ($r = 0.333$) qu'avec la pression systolique ($r = 0.195$).

5 Étude de la linéarité

Comme le projet porte sur la régression linéaire, il est important de vérifier si les relations entre la variable réponse et les variables explicatives peuvent être approximativement

modélisées par une droite.

Pour cela, nous avons représenté les nuages de points entre le BMI et chaque variable explicative.

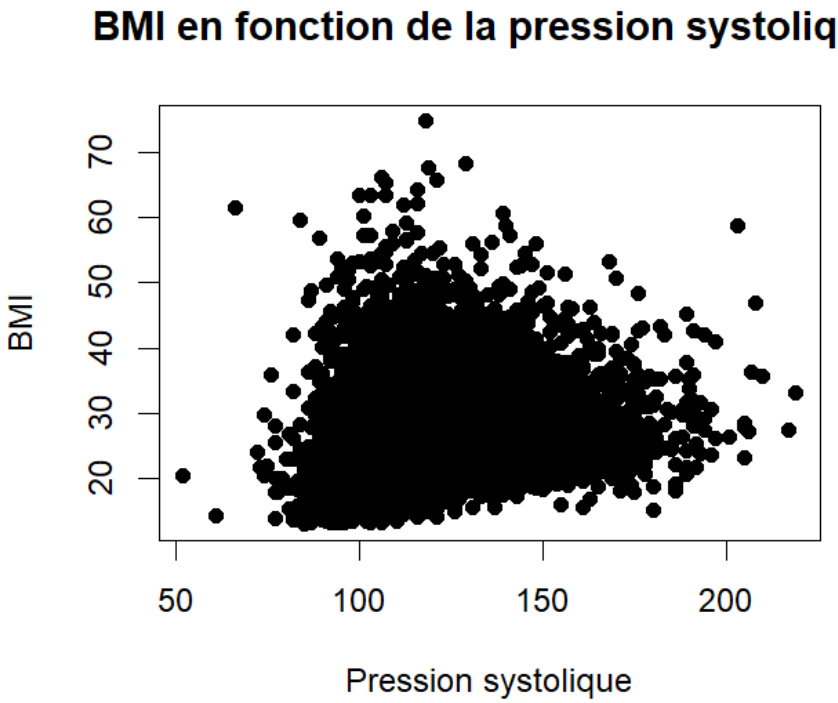


FIGURE 4 – Relation entre le BMI et la pression systolique

Une légère tendance croissante apparaît entre le BMI et la pression systolique, mais la dispersion importante des points indique une relation relativement faible.

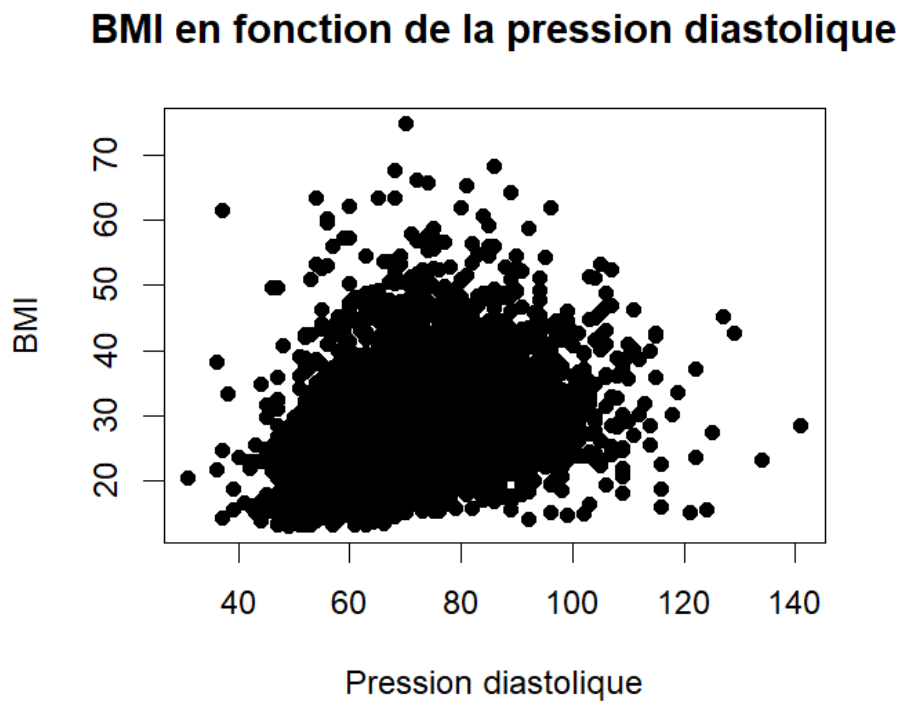


FIGURE 5 – Relation entre le BMI et la pression diastolique

Le BMI tend à augmenter avec la pression diastolique. Cette relation semble plus marquée que pour la pression systolique.

6 Régression linéaire simple

Dans un premier temps, nous ajustons un modèle de régression linéaire simple. La variable réponse est le BMI et la variable explicative est la pression systolique.

Le modèle s'écrit :

$$BMI_i = \beta_0 + \beta_1 \times pression_systolique_i + \varepsilon_i$$

où :

— β_0 est l'ordonnée à l'origine ;

— β_1 est le coefficient associé à la pression systolique ;

— ε_i représente l'erreur du modèle.

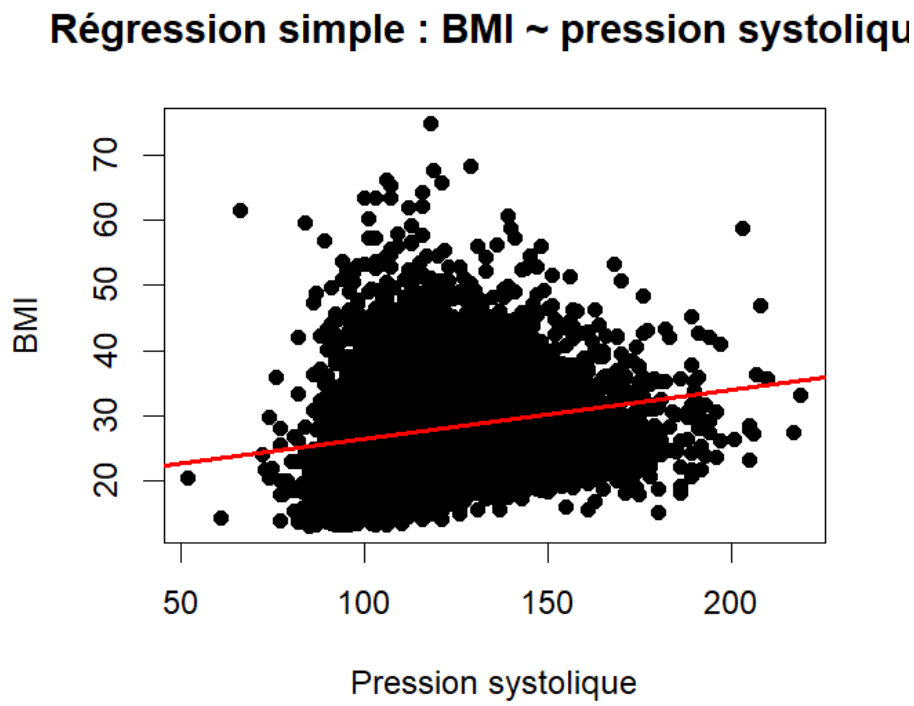


FIGURE 6 – Régression linéaire simple du BMI en fonction de la pression systolique

La droite de régression confirme une relation positive entre le BMI et la pression systolique. Cependant, la forte dispersion des observations explique le faible R^2 obtenu.

Variable	Coefficient	Erreur standard	t value	p-valeur
Intercept	19.0488	0.5926	32.15	$< 2e^{-16}$
Pression systolique	0.0751	0.0049	15.48	$< 2e^{-16}$

TABLE 6 – Résultats du modèle de régression linéaire simple

Indicateur	Valeur
Erreur standard résiduelle	7.586
Degrés de liberté	6055
R^2	0.0381
R^2 ajusté	0.0379
F-statistic	239.8
p-valeur globale	$< 2.2e^{-16}$

TABLE 7 – Qualité du modèle de régression simple

6.1 Test d'hypothèse sur la pente

On teste l'hypothèse suivante :

$$H_0 : \beta_1 = 0$$

contre :

$$H_1 : \beta_1 \neq 0$$

L'hypothèse nulle signifie que la pression systolique n'a pas d'effet significatif sur le BMI. La p-valeur est lue directement dans la sortie de la fonction `summary()`.

Dans le modèle simple, la p-valeur associée à la pression systolique est inférieure à $2e^{-16}$. Elle est donc inférieure à 0,05. On rejette l'hypothèse nulle $H_0 : \beta_1 = 0$. La pression systolique est donc significative pour expliquer le BMI dans ce modèle.

Le modèle estimé est :

$$\widehat{BMI} = 19.0488 + 0.0751 \times pression_systolique$$

Cependant, le coefficient de détermination est faible :

$$R^2 = 0.0381$$

Cela signifie que la pression systolique explique seulement environ 3,81 % de la variabilité du BMI.

7 Régression linéaire multiple

Nous construisons ensuite un modèle de régression linéaire multiple avec deux variables explicatives : la pression systolique et la pression diastolique.

Le modèle s'écrit :

$$BMI_i = \beta_0 + \beta_1 \times pression_systolique_i + \beta_2 \times pression_diastolique_i + \varepsilon_i$$

Le modèle multiple obtenu est :

$$\widehat{BMI} = 13.7222 - 0.0199 \times pression_systolique + 0.2326 \times pression_diastolique$$

Variable	Coefficient	Erreur standard	t value	p-valeur
Intercept	13.7222	0.6162	22.268	$< 2e^{-16}$
Pression systolique	-0.0199	0.0063	-3.172	0.00152
Pression diastolique	0.2326	0.0103	22.560	$< 2e^{-16}$

TABLE 8 – Résultats du modèle de régression linéaire multiple

Indicateur	Valeur
Erreur standard résiduelle	7.286
Degrés de liberté	6054
R^2	0.1127
R^2 ajusté	0.1124
F-statistic	384.4
p-valeur globale	$< 2.2e^{-16}$

TABLE 9 – Qualité du modèle de régression multiple

Dans ce modèle, les deux variables explicatives sont significatives au seuil de 5 %. La pression diastolique a un effet positif sur le BMI. La pression systolique a un coefficient légèrement négatif lorsque la pression diastolique est prise en compte dans le modèle.

Le coefficient de détermination du modèle multiple est :

$$R^2 = 0.1127$$

et le coefficient ajusté est :

$$R^2_{\text{ajusté}} = 0.1124$$

Le modèle multiple explique donc environ 11,27 % de la variabilité du BMI.

L'objectif est de vérifier si l'ajout de la pression diastolique améliore la qualité du modèle.

8 Sélection de variables

La sélection de variables permet de retenir un modèle plus simple et plus interprétable. Dans ce projet, nous utilisons plusieurs méthodes de sélection ou de comparaison :

— la méthode stepwise ;
— le R^2 ajusté ;
— le critère AIC ;
— le critère BIC ;
— le Cp de Mallows ;
— éventuellement le Lasso.

8.1 Méthode stepwise

La méthode stepwise permet de sélectionner automatiquement les variables à conserver dans le modèle. La méthode stepwise a été appliquée à partir du modèle complet contenant la pression systolique et la pression diastolique. La procédure conserve les deux variables explicatives.

Le modèle final retenu est donc :

$$\widehat{BMI} = 13.7222 - 0.0199 \times pression_systolique + 0.2326 \times pression_diastolique$$

Action	Df	Sum of Sq	RSS	AIC
Aucune suppression	–	–	321479	24062
Supprimer pression systolique	1	534	322013	24070
Supprimer pression diastolique	1	27026	348505	24549

TABLE 10 – Résultats de la sélection stepwise

Variable	Coefficient	Erreur standard	t value	p-valeur
Intercept	13.7222	0.6162	22.268	$< 2e^{-16}$
Pression systolique	-0.0199	0.0063	-3.172	0.00152
Pression diastolique	0.2326	0.0103	22.560	$< 2e^{-16}$

TABLE 11 – Modèle final retenu par la méthode stepwise

La méthode stepwise confirme donc le choix du modèle multiple comme modèle final.

9 Comparaison des modèles

Nous comparons les modèles suivants :
— modèle avec pression systolique seule ;
— modèle avec pression diastolique seule ;
— modèle avec pression systolique et pression diastolique.
Les critères utilisés sont le R^2, le R^2 ajusté, l'AIC et le BIC.

Modèle	R^2	R^2 ajusté	AIC	BIC
Pression systolique	0.0381	0.0379	41739.56	41759.69
Pression diastolique	0.1112	0.1111	41260.69	41280.81
Systolique + diastolique	0.1127	0.1124	41252.63	41279.47

TABLE 12 – Comparaison des modèles de régression

Le modèle utilisant à la fois la pression systolique et la pression diastolique présente le meilleur R^2 ajusté et le plus faible AIC. Il est donc retenu comme modèle final.

Le meilleur modèle est celui qui présente un bon compromis entre qualité d'ajustement et simplicité. Un R^2 ajusté plus élevé indique un meilleur pouvoir explicatif, tandis que des valeurs plus faibles de l'AIC et du BIC indiquent un meilleur modèle selon ces critères.

10 Cp de Mallows

Le Cp de Mallows est un critère permettant de comparer différents modèles en tenant compte du nombre de variables explicatives utilisées.

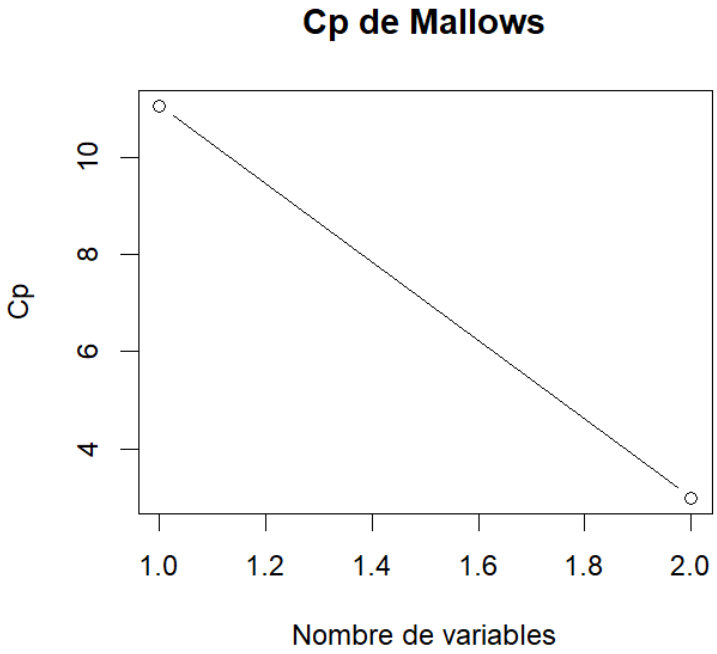


FIGURE 7 – Cp de Mallows selon le nombre de variables

Le critère de Mallows est plus faible pour le modèle contenant les deux variables, ce qui confirme qu'il constitue le meilleur compromis entre ajustement et complexité.

Modèle	Cp de Mallows	R^2 ajusté
Pression diastolique seule	11.0592	0.1111
Pression systolique + pression diastolique	3.0000	0.1124

TABLE 13 – Résultats du Cp de Mallows

11 Sélection par Lasso

Le Lasso est une méthode de sélection pénalisée. Elle peut réduire certains coefficients jusqu'à zéro, ce qui permet d'effectuer une sélection automatique de variables.

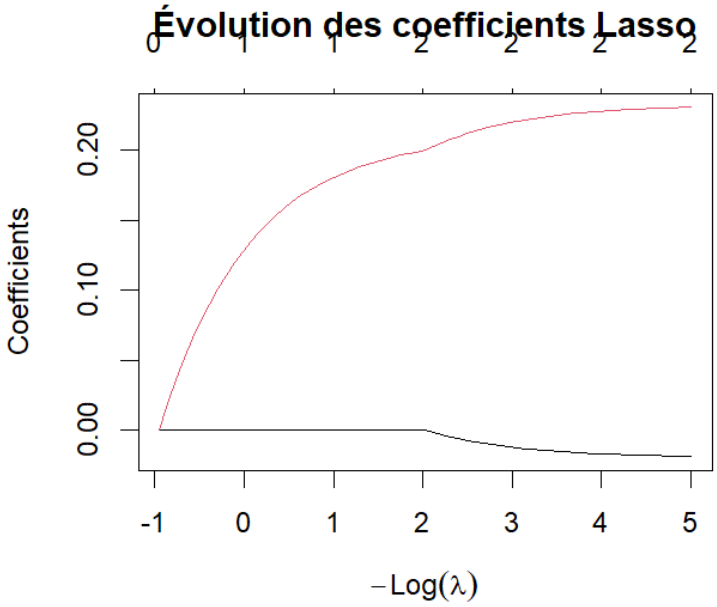


FIGURE 8 – Évolution des coefficients avec la méthode Lasso

Les deux coefficients restent non nuls lorsque la pénalisation diminue, ce qui confirme leur contribution à l'explication du BMI.

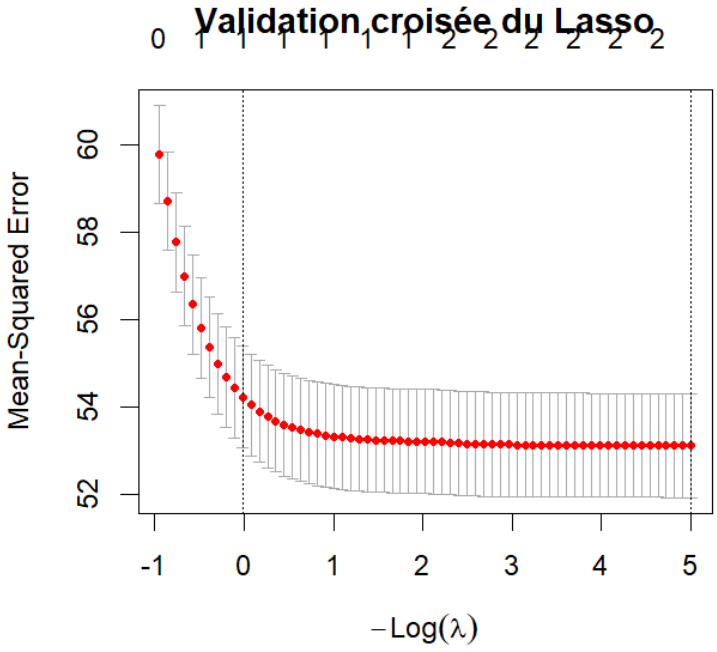


FIGURE 9 – Validation croisée du Lasso

La validation croisée permet de sélectionner la valeur optimale de λ, offrant le meilleur compromis entre précision et complexité du modèle.

Paramètre	Valeur
λ optimal	0.0067

TABLE 14 – Valeur optimale de lambda obtenue par validation croisée

Variable	Coefficient Lasso
Intercept	13.7166
Pression systolique	-0.0188
Pression diastolique	0.2308

TABLE 15 – Coefficients obtenus avec la méthode Lasso

Le Lasso conserve les deux variables explicatives. Les coefficients obtenus sont proches de ceux du modèle de régression linéaire multiple.

12 Analyse de la variance

Pour appliquer une analyse de la variance à un facteur, nous avons créé une variable qualitative appelée `categorie_pression`. Cette variable classe les observations selon le niveau de pression systolique.

La variable réponse reste le BMI, qui est quantitative. La variable explicative est `categorie_pression`, qui est qualitative.

On réalise ensuite une ANOVA pour tester si le BMI moyen varie significativement selon les catégories de pression.

Les hypothèses sont :

$$H_0 : \mu_1 = \mu_2 = \mu_3$$

contre :

$$H_1 : \text{au moins une moyenne est différente}$$

Catégorie de pression	Effectif
Normale	3375
Élevée	1700
Hypertension	982

TABLE 16 – Effectifs par catégorie de pression

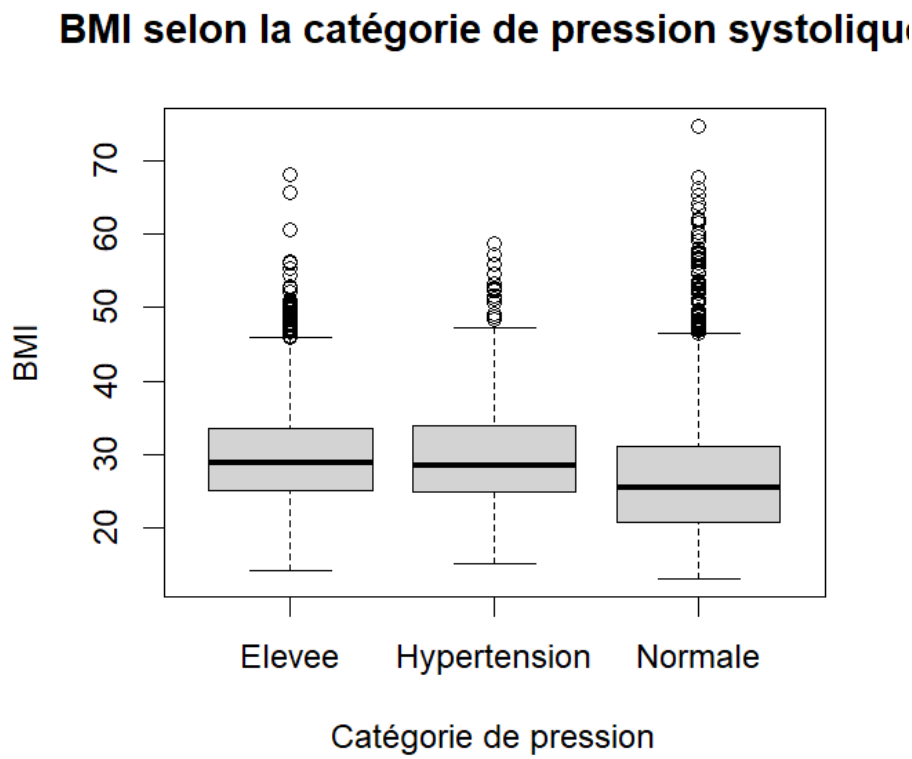


FIGURE 10 – BMI selon la catégorie de pression systolique

Les distributions du BMI diffèrent selon les catégories de pression systolique, ce qui suggère une relation entre ces deux variables.

Source	Df	Sum Sq	Mean Sq	F value	p-valeur
Catégorie de pression	2	13788	6894	119.8	$< 2e^{-16}$
Résidus	6054	348454	58	–	–

TABLE 17 – Résultat de l'ANOVA

Comparaison	Différence	Borne inférieure	Borne supérieure	p-valeur ajustée
Hypertension - Élevée	-0.0442	-0.7571	0.6687	0.9884
Normale - Élevée	-3.0535	-3.5825	-2.5246	0.0000
Normale - Hypertension	-3.0093	-3.6542	-2.3645	0.0000

TABLE 18 – Résultats du test de Tukey

13 Diagnostic du modèle final

Le diagnostic du modèle final permet de vérifier si les hypothèses de la régression linéaire sont raisonnablement respectées.

Les principales hypothèses étudiées sont :

— la linéarité ;
— la normalité des résidus ;
— l'homoscédasticité ;
— l'indépendance des erreurs ;
— l'absence de points trop influents.

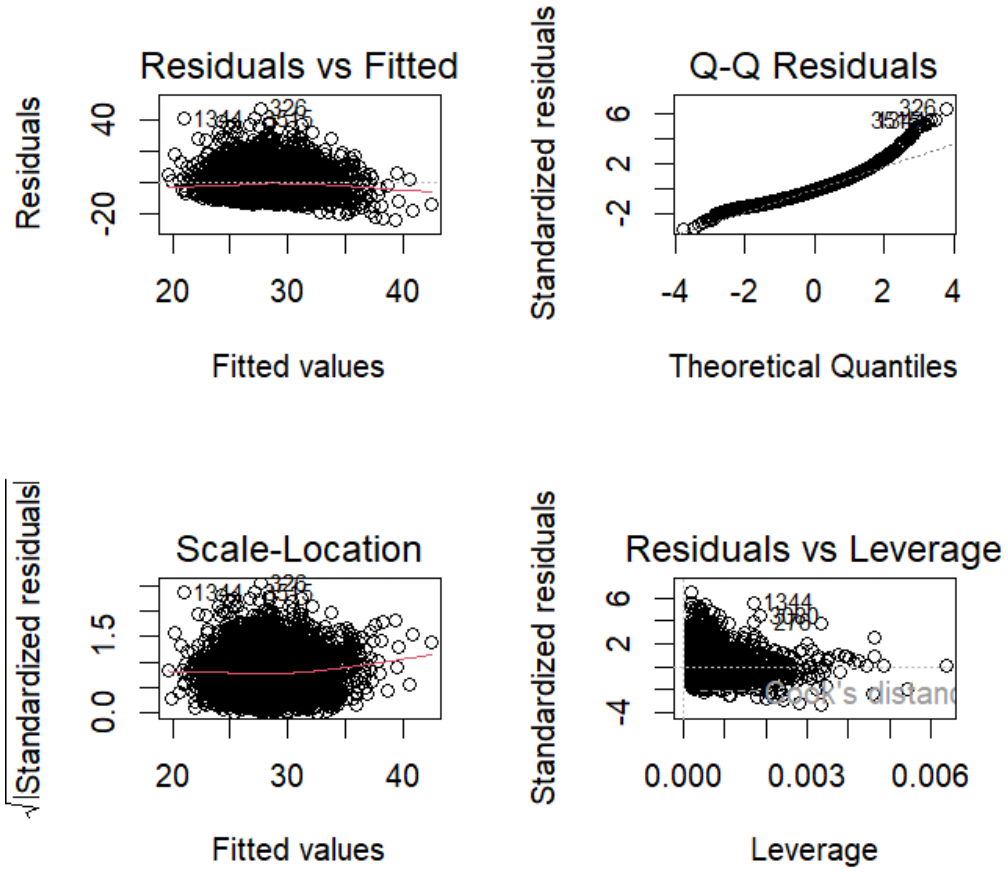


FIGURE 11 – Graphiques de diagnostic du modèle final

Les graphiques de diagnostic montrent que les hypothèses du modèle linéaire ne sont pas parfaitement respectées. Le graphique Q-Q indique que les résidus s'écartent de la normalité aux extrémités. Le graphique Scale-Location suggère aussi que la variance des résidus n'est pas totalement constante. Le modèle reste donc utilisable pour le projet, mais il doit être interprété avec prudence.

14 Analyse des résidus

Les résidus correspondent aux différences entre les valeurs observées et les valeurs prédites par le modèle.

$$e_i = y_i - \widehat{y_i}$$

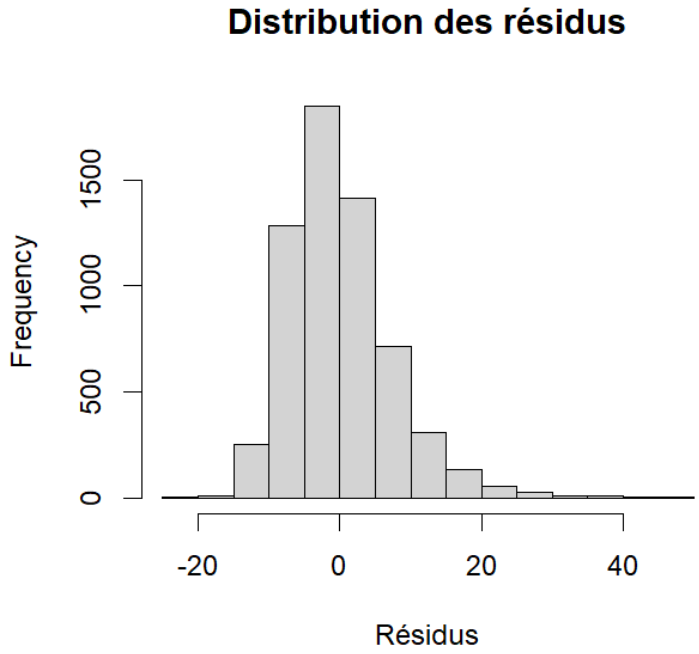


FIGURE 12 – Distribution des résidus du modèle final

Les résidus sont centrés autour de zéro mais présentent une légère asymétrie, ce qui explique le rejet de la normalité parfaite.

14.1 Test de normalité des résidus

Nous utilisons le test de Shapiro-Wilk pour vérifier la normalité des résidus. Comme le dataset contient un grand nombre d'observations, le test est appliqué sur un échantillon de 5000 résidus.

Les hypothèses sont :

$$H_0 : \text{les résidus suivent une loi normale}$$

contre :

$$H_1 : \text{les résidus ne suivent pas une loi normale}$$

Si la p-valeur est supérieure à 0,05, on ne rejette pas l'hypothèse de normalité. Si elle est inférieure à 0,05, on rejette l'hypothèse de normalité.

Élément	Valeur
Test	Shapiro-Wilk
Statistique	$W = 0.9473$
p-valeur	$< 2.2e^{-16}$

TABLE 19 – Résultat du test de Shapiro-Wilk

La p-valeur du test de Shapiro-Wilk est inférieure à 0,05. On rejette donc l'hypothèse de normalité des résidus. Les résidus ne suivent pas parfaitement une loi normale.

14.2 Test d'homoscédasticité

Le test de Breusch-Pagan permet de vérifier si la variance des résidus est constante.

Élément	Valeur
Test	Breusch-Pagan studentisé
Statistique	$BP = 47.449$
Degrés de liberté	2
p-valeur	4.972×10^{-11}

TABLE 20 – Résultat du test de Breusch-Pagan

La p-valeur du test de Breusch-Pagan est inférieure à 0,05. On rejette donc l'hypothèse d'homoscédasticité. La variance des résidus n'est pas parfaitement constante.

14.3 Test d'indépendance

Le test de Durbin-Watson permet de vérifier l'indépendance des erreurs.

Élément	Valeur
Test	Durbin-Watson
Statistique	$DW = 1.9736$
p-valeur	0.1518
Hypothèse alternative	autocorrélation positive

TABLE 21 – Résultat du test de Durbin-Watson

La p-valeur du test de Durbin-Watson est égale à 0.1518. Elle est supérieure à 0,05. On ne rejette donc pas l'hypothèse d'indépendance des erreurs. Il n'y a pas d'autocorrélation significative détectée.

15 Points influents

Les points influents sont des observations qui peuvent avoir un effet important sur l'estimation du modèle.

Nous utilisons notamment :

— les valeurs leverage ;
— la distance de Cook ;
— les résidus studentisés.

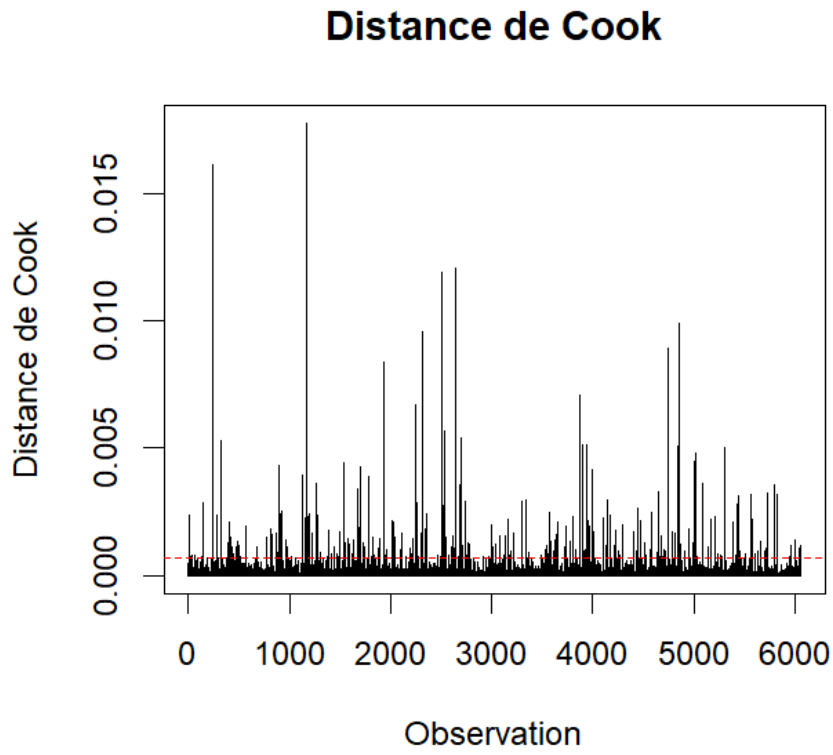


FIGURE 13 – Distance de Cook des observations

La plupart des observations ont une faible distance de Cook, indiquant l'absence de points fortement influents.

16 Prédiction

Le modèle final est ensuite utilisé pour prédire le BMI d'un nouveau patient fictif ayant :

— une pression systolique de 130 ;
— une pression diastolique de 85.

Le BMI prédit est ensuite transformé en catégorie fictive :

— BMI inférieur à 18,5 : insuffisance ;
— BMI entre 18,5 et 25 : normal ;
— BMI entre 25 et 30 : surpoids ;
— BMI supérieur ou égal à 30 : obésité.

Observation	BMI prédit	Borne inférieure	Borne supérieure
Pres syst = 130, pres diast = 85	30.90	16.62	45.19

TABLE 22 – Prédiction du BMI pour une nouvelle observation

Résultat	Valeur
BMI prédit	30.90
Catégorie prédite	Obésité

TABLE 23 – Catégorie associée au BMI prédit

Le BMI prédit est égal à 30.90. Selon les catégories définies dans ce projet, cette valeur correspond à la catégorie fictive **Obésité**.

Cette transformation est utilisée uniquement pour faciliter l'interprétation du résultat. Elle ne constitue pas un diagnostic médical.

17 Interprétation et validité du modèle final

Le modèle final permet d'étudier la relation entre le BMI et les variables de pression artérielle. Les résultats montrent une relation globalement positive entre ces variables. Cependant, le pouvoir explicatif du modèle reste limité.

Pour le modèle final, on obtient :

$$R^2 = 0.1127$$

et :

$$R^2_{\text{ajusté}} = 0.1124$$

Cela signifie que le modèle explique environ 11,27 % de la variabilité du BMI. Le pouvoir explicatif du modèle reste donc limité.

Cela signifie que la pression systolique et la pression diastolique n'expliquent qu'une partie de la variabilité du BMI. D'autres variables, comme l'âge, le sexe, l'alimentation, l'activité physique ou les antécédents médicaux, pourraient probablement améliorer le modèle.

Le modèle reste donc utile pour appliquer les méthodes de régression linéaire vues en cours, mais il ne doit pas être utilisé comme outil médical réel.

18 Conclusion

Dans ce projet, nous avons étudié un dataset réel portant sur le BMI et la pression artérielle. Après avoir nettoyé les données et réalisé une analyse descriptive, nous avons construit plusieurs modèles de régression linéaire.

La régression linéaire simple a permis d'étudier séparément l'effet de la pression systolique sur le BMI. La régression linéaire multiple a ensuite permis de prendre en compte à la fois la pression systolique et la pression diastolique.

Nous avons comparé les modèles à l'aide du R^2, du R^2 ajusté, de l'AIC, du BIC et du Cp de Mallows. Une sélection de variables a également été réalisée avec la méthode stepwise et le Lasso.

Les diagnostics du modèle final ont permis d'évaluer la validité des hypothèses de la régression linéaire. Enfin, une prédiction a été réalisée pour une nouvelle observation fictive.

Les résultats obtenus montrent que la relation entre le BMI et la pression artérielle existe, mais reste relativement faible. Le modèle est donc intéressant d'un point de vue pédagogique, mais il possède des limites importantes pour une utilisation concrète.

Annexe – Code R complet

```r
set.seed(300)

# ============================================================
# 1. Chargement des packages
# ============================================================

# install.packages("lmtest")
# install.packages("leaps")
# install.packages("glmnet")

library(lmtest)
library(leaps)
library(glmnet)

# ============================================================
# 2. Chargement du dataset
# ============================================================

load("BMI_Dataset.RData")


ls()


objets <- ls()
dataframes <- objets[sapply(objets, function(x) is.data.frame(get(x
   )))]

datafile <- get(dataframes[1])


head(datafile)
dim(datafile)
names(datafile)
str(datafile)
summary(datafile)

# ============================================================
# 3. Renommer les variables
# ============================================================

# BMI   = indice de masse corporelle
# BP_Sy = pression systolique
# BP_Di = pression diastolique

datafile$bmi <- as.numeric(datafile$BMI)
```

```r
datafile$pression_systolique <- as.numeric(as.character(datafile$BP
   _Sy))
datafile$pression_diastolique <- as.numeric(as.character(datafile$
   BP_Di))

datafile <- datafile[, c("bmi",
                         "pression_systolique",
                         "pression_diastolique")]


head(datafile)
str(datafile)
summary(datafile)

# ============================================================
# 4. Nettoyage des donn es
# ============================================================

# Valeurs manquantes
sum(is.na(datafile))
colSums(is.na(datafile))

# Suppression des lignes avec valeurs manquantes
datafile <- na.omit(datafile)

# Doublons
sum(duplicated(datafile))

# Suppression des doublons
datafile <- datafile[!duplicated(datafile), ]

# V rification finale
sum(is.na(datafile))
sum(duplicated(datafile))
dim(datafile)

# ============================================================
# 5. Cr ation d'une variable qualitative ind pendante pour ANOVA
# ============================================================



datafile$categorie_pression <- ifelse(datafile$pression_systolique
   < 120,
                                      "Normale",
                                      ifelse(datafile$pression_
                                         systolique < 140,
                                             "Elevee",
                                             "Hypertension"))
```

```r
datafile$categorie_pression <- as.factor(datafile$categorie_
   pression)

table(datafile$categorie_pression)

# ============================================================
# 6. Analyse descriptive
# ============================================================

summary(datafile)

mean(datafile$bmi)
median(datafile$bmi)
sd(datafile$bmi)
min(datafile$bmi)
max(datafile$bmi)

mean(datafile$pression_systolique)
sd(datafile$pression_systolique)

mean(datafile$pression_diastolique)
sd(datafile$pression_diastolique)


hist(datafile$bmi,
     main = "Distribution␣du␣BMI",
     xlab = "BMI")


hist(datafile$pression_systolique,
     main = "Distribution␣de␣la␣pression␣systolique",
     xlab = "Pression␣systolique")


hist(datafile$pression_diastolique,
     main = "Distribution␣de␣la␣pression␣diastolique",
     xlab = "Pression␣diastolique")


boxplot(bmi ~ categorie_pression,
        data = datafile,
        main = "BMI␣selon␣la␣cat gorie␣de␣pression␣systolique",
        xlab = "Cat gorie␣de␣pression",
        ylab = "BMI")

# ============================================================
# 7. Corr lations
# ============================================================

cor(datafile$bmi, datafile$pression_systolique)
cor(datafile$bmi, datafile$pression_diastolique)
```

```r
cor(datafile[, c("bmi",
                 "pression_systolique",
                 "pression_diastolique")])


plot(datafile$pression_systolique,
     datafile$bmi,
     main = "BMI en fonction de la pression systolique",
     xlab = "Pression systolique",
     ylab = "BMI",
     pch = 16)


plot(datafile$pression_diastolique,
     datafile$bmi,
     main = "BMI en fonction de la pression diastolique",
     xlab = "Pression diastolique",
     ylab = "BMI",
     pch = 16)

# ============================================================
# 8. R gression lin aire simple
# ============================================================


model_simple <- lm(bmi ~ pression_systolique, data = datafile)

summary(model_simple)


plot(datafile$pression_systolique,
     datafile$bmi,
     main = "R gression simple : BMI ~ pression systolique",
     xlab = "Pression systolique",
     ylab = "BMI",
     pch = 16)

abline(model_simple, col = "red", lwd = 2)



# ============================================================
# 9. R gression lin aire multiple
# ============================================================

model_full <- lm(bmi ~ pression_systolique + pression_diastolique,
                 data = datafile)

summary(model_full)
```

```r
# ============================================================
# 10. Comparaison des mod les
# ============================================================

model_sy <- lm(bmi ~ pression_systolique, data = datafile)

model_di <- lm(bmi ~ pression_diastolique, data = datafile)

model_sy_di <- lm(bmi ~ pression_systolique + pression_diastolique,
                  data = datafile)

comparaison <- data.frame(
  Modele = c("pression␣systolique",
             "pression␣diastolique",
             "pression␣systolique␣+␣diastolique"),

  R2 = c(summary(model_sy)$r.squared,
         summary(model_di)$r.squared,
         summary(model_sy_di)$r.squared),

  R2_ajuste = c(summary(model_sy)$adj.r.squared,
                summary(model_di)$adj.r.squared,
                summary(model_sy_di)$adj.r.squared),

  AIC = c(AIC(model_sy),
          AIC(model_di),
          AIC(model_sy_di)),

  BIC = c(BIC(model_sy),
          BIC(model_di),
          BIC(model_sy_di))
)

comparaison

# ============================================================
# 11. S lection stepwise
# ============================================================

model_step <- step(model_full, direction = "both")

summary(model_step)

model_final <- model_step

# ============================================================
# 12. S lection Lasso
# ============================================================

X <- model.matrix(bmi ~ pression_systolique + pression_diastolique,
                  data = datafile)[, -1]
```

```r
Y <- datafile$bmi

lasso_model <- glmnet(X, Y, alpha = 1)

plot(lasso_model,
     main = "  volution  des coefficients Lasso")

cv_lasso <- cv.glmnet(X, Y, alpha = 1)

plot(cv_lasso,
     main = "Validation crois e du Lasso")

best_lambda <- cv_lasso$lambda.min
best_lambda

coef(cv_lasso, s = "lambda.min")

# ============================================================
# 13. Cp de Mallows
# ============================================================

reg_subset <- regsubsets(bmi ~ pression_systolique + pression_
   diastolique,
                         data = datafile,
                         nvmax = 2)

res_subset <- summary(reg_subset)

res_subset$cp
res_subset$adjr2
res_subset$outmat

plot(res_subset$cp,
     type = "b",
     main = "Cp de Mallows",
     xlab = "Nombre de variables",
     ylab = "Cp")

abline(0, 1, col = "red", lty = 2)

# ============================================================
# 14. ANOVA
# ============================================================

# on   tudie   si le BMI moyen varie selon la cat gorie de pression.


boxplot(bmi ~ categorie_pression,
        data = datafile,
        main = "BMI selon la cat gorie de pression systolique",
```

```
        xlab = "Cat gorie de pression",
        ylab = "BMI")

anova_pression <- aov(bmi ~ categorie_pression, data = datafile)

summary(anova_pression)

TukeyHSD(anova_pression)


# ============================================================
# 15. Diagnostic du mod le final
# ============================================================

par(mfrow = c(2, 2))
plot(model_final)
par(mfrow = c(1, 1))

residus <- residuals(model_final)

hist(residus,
     main = "Distribution des r sidus",
     xlab = "R sidus")


set.seed(300)
residus_sample <- sample(residus, size = 5000)

shapiro.test(residus_sample)#verifier si elle suit la loi normsl

bptest(model_final)

dwtest(model_final)

# ============================================================
# 16. Points influents
# ============================================================

hat_vals <- hatvalues(model_final)

seuil_hat <- 2 * length(coef(model_final)) / nrow(datafile)

which(hat_vals > seuil_hat)

cook <- cooks.distance(model_final)

plot(cook,
     type = "h",
     main = "Distance de Cook",
     xlab = "Observation",
     ylab = "Distance de Cook")
```

```r
abline(h = 4 / nrow(datafile), col = "red", lty = 2)

which(cook > 4 / nrow(datafile))

rstud <- rstudent(model_final)

which(abs(rstud) > 2)

# ============================================================
# 17. Pr diction pour une nouvelle observation
# ============================================================



names(coef(model_final))

nouveau_patient <- data.frame(
  pression_systolique = 130,
  pression_diastolique = 85
)

prediction <- predict(model_final,
                      newdata = nouveau_patient,
                      interval = "prediction",
                      level = 0.95)

prediction

bmi_predit <- prediction[1, "fit"]

bmi_predit

# ============================================================
# 18. Cat gorie du BMI pr dit
# ============================================================

categorie_predite <- ifelse(bmi_predit < 18.5,
                            "Insuffisance",
                            ifelse(bmi_predit < 25,
                                   "Normal",
                                   ifelse(bmi_predit < 30,
                                          "Surpoids",
                                          "Obesite")))

categorie_predite

cat("BMI pr dit :", round(bmi_predit, 2), "\n")
cat("Cat gorie pr dite :", categorie_predite, "\n")
```